潮汐 TIDE

seekdb × 阶跃星辰 | 浏览器本地知识库 | 一页技术说明 | 2026-10-28

01 模型与量化

公开模型 Xenova/bge-small-zh-v1.5，源自 BAAI；固定版本 75c43b069aac4d136ba6bc1122f995fedcfd2781。使用上游 FP32、FP16、INT8 ONNX 图，INT8 为 QInt8 / per-channel / reduce_range；不训练模型，下载时校验 SHA-256。CLS pooling + L2 归一化，512 维、最多 256 tokens；查询添加 BGE 中文检索前缀。FP16 / INT8 权重压缩比为 1.997× / 3.950×；计入相同 tokenizer/config，完整包大小为 95.402 / 48.047 / 24.561 MB，压缩比为 1.986× / 3.884×。

02 端侧运行与降级

Transformers.js 3.8.1 在持久化 Web Worker 中计算文档与查询 embedding。自动模式显式选择 device:webgpu、dtype:fp16，并检查 adapter 与 shader-f16；不可用或初始化失败时切换 device:wasm、dtype:q8（单线程）。界面显示实际后端与降级原因。模型和 ORT 文件本机提供，关闭远程模型加载，Node 禁止 embedding 推理，无云端推理 API。

03 seekdb、增量与状态

seekdb-js 1.4.0 连接本地 seekdb 1.4.0，Docker 镜像锁定 digest。每库独立集合保存正文、向量、文档 ID、标题、来源与片段序号，使用 cosine HNSW 与 IK smart 全文索引。hybridSearch 调用数据库 DBMS_HYBRID_SEARCH，两路各召回 30，数据库 RRF(60) 返回 Top K，应用保留数据库次序。32 条批量 upsert 后同步刷新索引；刷新成功更新版本，未刷新时拒绝检索。集合注册与版本状态也存于 seekdb，全局串行队列避免 SDK 会话交叉。180 字符分块、重叠 24，稳定 SHA-256 去重；切库清空结果并忽略旧请求。

04 实测与优化

Windows / i7-14650HX / 16GB，默认 GPU 适配器未指定独显；固定内置 Chromium（UA Chrome/156.0.0.0）。16 文档、12 条人工分级查询，6 配置各重复 3 次，共 18 轮、216 个后续查询样本，失败 0。表中均为中位数；MB 为十进制 ONNX 权重大小，查询延迟不含模型加载及首次数据库请求。

配置 / 推理批次	权重 MB	吞吐 块/s	seekdb ms	端到端 ms	Recall@5 / nDCG@5
FP32 / WASM / 1	94.852	15.78	4.89	44.08	.8889 / .9589
INT8 / WASM / 8	24.011	19.90	5.19	37.44	.9306 / .9644
FP32 / WebGPU / 1	94.852	90.42	4.68	22.58	.8889 / .9589
FP16 / WebGPU / 8	47.497	366.85	5.56	27.31	.9306 / .9644

FP16/WebGPU 文档吞吐组合提升 4.06×，查询端到端延迟从 22.58 增至 27.31 ms。INT8/WASM 批次消融：1 → 8 时吞吐 16.29 → 19.90（+22.2%）；逐条写入/刷新累计刷新 9722 ms，批量统一刷新为 517 ms。组合提升不能单独归因于量化。量化后本集 Recall +4.17 个百分点、nDCG +.0055，小样本不代表普遍改善。每组首轮清模型 Cache Storage，后两轮复用；HTTP 磁盘缓存不清除。

05 验收与复现

独立 Chrome 156.0.8078.73、Edge 156.0.4314.50，可见窗口与 headless 各 6/6 通过：WebGPU 优先、禁用 GPU 后页面/Worker 均无 adapter 并自动 WASM、FP16 文件加载失败后自动 WASM；均完成真实导入、刷新、检索、原文、去重、增量与集合隔离。未测试驱动崩溃或执行中设备丢失。启动：npm ci → npm run db:up → npm run models:download → npm run build → npm start；打开 127.0.0.1:8788，性能实验室运行评测，npm run test:browsers 执行补测。

原始计时、首次/后续加载与质量标注：reports/browser-benchmark.json、reports/BENCHMARK.md；降级证据：reports/native-browser/。模型：huggingface.co/Xenova/bge-small-zh-v1.5；SDK：github.com/oceanbase/seekdb-js。依赖、详细启动步骤、模型获取与量化来源见 README.md；编辑版见 docs/TECHNICAL.md。